Facultad de la Energía, las Industrias y los Recursos Naturales No Renovables

Universidad Nacional de Loja

Carrera de Computación

Evaluación de los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos

Proyecto de Investigación de Integración Curricular
Itinerario: Sistemas Inteligentes

Autor: Geovanny Ismael Romero Suquilanda, geovanny.romero@unl.edu.ec
Asesor: Oscar Miguel Cumbicus Pineda, oscar.cumbicus@unl.edu.ec

Profesor: Oscar Miguel Cumbicus Pineda

Loja – Ecuador
2025

Certificación de Asesoría

En calidad de Asesor del Proyecto de Trabajo de Integración Curricular titulado **Evaluación de los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos**, certifico la asesoría a **Geovanny Ismael Romero Suquilanda**, quien ha cumplido con todas las observaciones requeridas. Es todo cuanto puedo decir en honor a la verdad, facultando al interesado hacer uso de la presente, así como el trámite de solicitud de pertinencia del presente proyecto.

Loja 22 de julio de 2026

Atentamente

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
OSCAR MIGUEL
CUMBICUS PINEDA

Oscar Miguel Cumbicus Pineda
ASESOR

Certificación de Autoría del Proyecto

Yo Geovanny Ismael Romero Suquilanda, estudiante de la Universidad Nacional de Loja, declaro en forma libre y voluntaria que el presente Proyecto de Trabajo de Integración Curricular que versa **Evaluación de los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos**, así como las expresiones vertidas en el mismo son autoría del compareciente, quien ha realizado en base a recopilación bibliográfica primaria y secundaria. En consecuencia, asumo la responsabilidad de la originalidad de este y el cuidado al remitirse a las fuentes bibliográficas respectivas para fundamentar el contenido expuesto.

Loja 22 de julio de 2026

Atentamente

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
GEOVANNY ISMAEL
ROMERO SUQUILANDA

Geovanny Ismael Romero Suquilanda
AUTOR

Índice

1 Evaluación de los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos **1**

2 Problema de investigación **2**
2.1 Situación Problemática 2
2.2 Pregunta de investigación 4
2.3 Justificación 4

3 Objetivos **6**
3.1 Objetivo General 6
3.2 Objetivos Específicos 6
3.3 Alcance de proyecto 6
3.3.1 Fase 1(Objetivo Específico 1) 7
3.3.2 Fase 2(Objetivo Específico 2) 8
3.4 Limitaciones del proyecto 9
3.5 Resumen del alcance del proyecto 10

4 Metodología **12**
4.1 Consideraciones éticas 12
4.2 Resumen de la metodología 13

5 Marco Teórico **15**
5.1 Fundamentos teóricos 15
5.1.1 Calidad y defectos en semillas de maíz 15
5.1.2 Inteligencia Artificial (IA) 15
5.1.3 Machine Learning (ML) 16
5.1.4 Deep Learning (DL) 16
5.1.5 Visión por Computador 17
5.1.6 Detección de Objetos 17
5.1.7 Redes Neuronales Convolucionales (CNN) 18
5.2 Modelos, métodos y técnicas 18
5.2.1 Arquitecturas de detección de una sola etapa (One-stage detectors) . 18
5.2.2 Familia YOLO (You Only Look Once) 19
5.2.3 Metodología CRISP-ML(Q) 20
5.2.4 Transferencia de Aprendizaje (Transfer Learning) 21
5.2.5 Ajuste Fino (Fine-Tuning) 21

5.2.6 Técnicas de Ingeniería de Datos 22
5.2.7 Aumento de datos (Data Augmentation) 22
5.2.8 Métricas de Evaluación 22
5.3 Trabajos relacionados 24
5.4 Aporte del marco teórico al proyecto 27

6 Cronograma de actividades **29**

7 Presupuesto y financiamiento **31**
7.1 Talento humano 31
7.2 Servicios 32
7.3 Hardware 32
7.4 Software 32
7.5 Resumen del presupuesto 33

8 Bibliografía **34**

9 Anexos **38**
9.1 Declaración de uso de Inteligencia Artificial Generativa 38
9.2 Reporte Antiplagio 39
9.3 Reporte de asesorias 41

Índice de Figuras

1 Muestras de granos de maíz cosechados a máquina. (a) Granos enteros; (b) Granos quebrados; (c) Granos con moho; (d) Impurezas [21]. 15
2 Organización y relación de la Inteligencia Artificial con el Aprendizaje Automático y Aprendizaje Profundo [22]. 16
3 Proceso de la deteccion de objetos en una imagen [24]. 17
4 Arquitectura de una CNN con una capa convolucional, una capa de agrupación (Pooling) y una capa totalmente conectada [23]. 18
5 Deteccion de objetos con YOLO [27]. 19
6 Ejemplo de aumento de datos aplicando rotaciones, volteos y ruido gaussiano [1]. 22

Índice de Tablas

I Resumen de las actividades por cada objetivo. 11
II Metodología aplicada al proyecto (Basada en CRISP-ML(Q)). 14
III Resumen de trabajos relacionados. 25
IV Cronograma detallado de actividades por semanas. 30
V Presupuesto de Talento Humano 31
VI Presupuesto de Servicios 32
VII Presupuesto de Hardware 32
VIII Presupuesto de Software 33
IX Resumen del presupuesto general 33

Índice de Ecuaciones

1 Precisión (Precision) 23
2 Sensibilidad o Recuperación (Recall) 23
3 Precisión Promedio (AP) 23
4 Precisión Promedio Media (mAP) 24
5 Fotogramas por Segundo (FPS) 24

1. Evaluación de los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos

2. Problema de investigación

En esta sección se presenta la problemática actual en el control de calidad de las semillas de maíz, un proceso que habitualmente depende de inspecciones manuales ineficientes y subjetivas. Esto dificulta la detección oportuna de daños mecánicos y biológicos, generando importantes pérdidas económicas y riesgos sanitarios. Ante este escenario, se delimita la pregunta central del estudio y se justifica la necesidad de implementar sistemas automatizados de visión artificial basados en arquitecturas YOLOv11 para optimizar dicha evaluación.

2.1. Situación Problemática

En la producción y procesamiento del maíz, uno de los principales desafíos es el impacto de los daños mecánicos y biológicos que sufren las semillas durante los procesos de cosecha mecánica, transporte y almacenamiento. Factores como las roturas, la germinación prematura y el desarrollo de moho reducen la viabilidad y calidad de la semilla para la siembra [1][2][3]. Específicamente, el deterioro por moho favorece la aparición de microorganismos que metabolizan micotoxinas tóxicas como la aflatoxina y la zearalenona, las cuales disminuyen la tasa de germinación, incrementa la susceptibilidad a enfermedades y provocan graves pérdidas económicas y riesgos sanitarios en la industria alimentaria y ganadera. En la actualidad, la evaluación de calidad de las semillas de maíz en la mayoría de las plantas de procesamiento depende predominantemente de métodos de inspección manual. Este proceso basado en el criterio visual humano es ineficiente, costoso y altamente susceptible a errores debido a la subjetividad y la fatiga de los operadores al procesar grandes volúmenes de granos [1][4].

La evaluación automatizada de calidad agrícola mediante visión artificial se fundamenta en modelos de aprendizaje profundo que identifican patrones a partir de imágenes. En este contexto, las redes neuronales convolucionales (CNN) permiten extraer de forma automática características visuales complejas como el color, la textura y la forma de las semillas, disminuyendo la subjetividad de los métodos tradicionales [5][2]. A su vez, la tarea de detección de objetos amplía esta capacidad al localizar y clasificar simultáneamente múltiples elementos dentro de una misma escena [6]. Para entornos que demandan alta velocidad, los algoritmos de detección de una sola etapa, como las arquitecturas YOLO (You Only Look Once), procesan la imagen completa en una única pasada de la red para predecir las categorías y sus ubicaciones espaciales de manera directa [7][2], logrando un punto medio entre precisión y velocidad de inferencia en tiempo real [2][4], a diferencia de modelos de dos etapas que llegan a ser más precisos, pero sacrifican eficiencia computacional [8].

Las investigaciones [1], [2], [3], [4], [6] y [9] han abordado la detección de calidad y clasificación de variedades en semillas de maíz mediante aprendizaje profundo. Específicamente, en los estudios [1], [3], [4], [6] y [9] se implementaron modificaciones en la arquitectura YOLOv5, v7 y v8, integrando mecanismos de atención y redes ligeras como FasterNet, MobileNetV3 y ShuffleNet, logrando precisiones hasta el 96 %. Por otro lado para el conteo, en los trabajos [10] y [11] se han implementado algoritmos de seguimiento como ByteTrack, alcanzado precisiones superiores al 99 %. Asimismo, en las investigaciones [12] y [13] se exploró modelos Vision Transformer y enfoques híbridos, en el artículo [13] se aplicó un Swin Transformer mejorado con fusión de características, obteniendo un 96.53 % de precisión, a su vez en el artículo [14] se combinó detección YOLO con segmentación U^2-Net y clasificación SVM. A pesar de estos importantes avances, en los estudios [7] y [3] se constata que la detección pierde eficacia ante escenarios de alta densidad de semillas, oclusión severa y recursos computacionales limitados.

Esta investigación se alinea con el ODS 9 (Industria, innovación e infraestructura), cumpliendo la meta 9.5 al mejorar la capacidad tecnológica e impulsar la investigación científica en el sector agroindustrial [15]. A nivel nacional, el proyecto se justifica en la Estrategia para el fomento de la IA en el Ecuador, dentro del Eje 2: "Capacidad y Tecnología"[16], porque fomenta directamente la investigación aplicada y el desarrollo de talento humano especializado en modelos de inteligencia artificial. Académicamente, se enmarca en la línea "Industria, Innovación y Desarrollo Tecnológico"de la UNL [17], ya que atiende al objetivo de diseñar soluciones mediante inteligencia artificial para necesidades productivas e industriales. Finalmente, el procesamiento de la información se regirá por los principios de tratamiento y transparencia de la Ley Orgánica de Protección de Datos Personales [18].

Este trabajo de integración curricular, tiene como propósito implementar y evaluar comparativamente modelos de detección de objetos basados en YOLOv11 para la identificación, clasificación y conteo de granos de maíz sanos y con defectos superficiales, orientado a determinar el equilibrio óptimo entre precisión, velocidad de inferencia y consumo de recursos computacionales en escenarios controlados. El estudio se enfoca en arquitecturas ligeras (como variantes small y nano), adaptándose a contextos con limitaciones de hardware. Se utilizará un dataset público de Roboflow Universe, previamente etiquetado y acondicionado para tareas de detección. El desarrollo se realizará en Python utilizando el framework PyTorch y la librería Ultralytics para la implementación de los modelos. La evaluación se llevará a cabo mediante métricas como precision, recall, mAP@0.5 y tiempo de inferencia (FPS). Finalmente, los resultados permitirán establecer criterios comparativos sobre el desempeño de cada versión aportando evidencia en un contexto experimental.

2.2. Pregunta de investigación

¿Cuál es el nivel de precisión (precision, recall, mAP@0.5) y de eficiencia de inferencia (FPS) obtenido al ajustar y comparar los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos superficiales, utilizando un dataset público de Roboflow Universe?

2.3. Justificación

El maíz es uno de los cultivos de cereales más importantes a nivel mundial, siendo un pilar fundamental para la seguridad alimentaria, la ganadería y diversas aplicaciones industriales [19][1]. Debido a su alto contenido de humedad y a la estructura de su endospermo rico en almidón, las semillas son altamente susceptibles a sufrir daños mecánicos e infecciones fúngicas durante las etapas de poscosecha y almacenamiento, lo que facilita la proliferación de moho y la producción de micotoxinas (como la aflatoxina)[1][4]. Tradicionalmente, la evaluación de la calidad de estas semillas se ha realizado mediante métodos manuales basados en el criterio visual de los operarios. Esta práctica resulta ineficiente, laboriosa y propensa a sesgos subjetivos que no logran reflejar objetivamente el estado real de los granos [4]. Por tanto, es imperativa la adopción de tecnologías de visión artificial y aprendizaje profundo que permitan una clasificación rápida y objetiva.

A nivel científico el presente estudio aportaría al conocimiento en el campo de la visión computacional agrícola mediante la evaluación y comparación de modelos de detección de objetos de alta eficiencia (YOLOv11s, YOLOv11n). De esta manera, se generaría evidencia empírica clave sobre el equilibrio óptimo entre la precisión de detección y la velocidad de inferencia. Este análisis comparativo establecería un marco de referencia esencial para la selección de arquitecturas ligeras que resulten viables para ser desplegadas en dispositivos con recursos computacionales limitados dentro del sector agroindustrial.

La investigación responde directamente a la necesidad de mitigar los graves riesgos a la salud pública y las significativas pérdidas económicas en la producción agrícola asociadas al mal estado del maíz. Al determinar la arquitectura más eficiente, se brindará una solución tecnológica práctica que permitirá sustituir los ineficientes métodos manuales, optimizando los recursos y garantizando la calidad del producto final antes de su procesamiento.

Los principales beneficiarios serán los agricultores y las plantas de procesamiento agroindustrial, quienes dispondrán de los fundamentos tecnológicos necesarios para implementar sistemas que disminuyan costos operativos, eviten el desperdicio y mejoren el valor comercial

del maíz. Adicionalmente, la comunidad científica y académica se beneficiará de los hallazgos sobre el rendimiento comparativo de modelos ligeros frente a aplicaciones específicas, contribuyendo a la literatura en el campo de la visión artificial aplicada a la agricultura.

El desarrollo tecnológico planteado se alinea estratégicamente con los Objetivos de Desarrollo Sostenible (ODS) propuestos por las Naciones Unidas. Específicamente, contribuye al ODS 9 (Industria, Innovación e Infraestructura) [15] mediante el fomento de la innovación técnica en los procesos agroindustriales. A nivel nacional, el proyecto guarda coherencia con la "Estrategia para el Fomento del Desarrollo y Uso Ético y Responsable de la Inteligencia Artificial en el Ecuador"[16], la cual impulsa la adopción de tecnologías de IA orientadas a cumplir los ODS, mejorar la economía nacional e incentivar soluciones tecnológicas sostenibles.

Desde la perspectiva del entorno académico, este estudio tiene como propósito fundamental demostrar, consolidar y aplicar de manera práctica los conocimientos teóricos y técnicos adquiridos a lo largo de la Carrera de Computación de la Universidad Nacional de Loja. Específicamente, el estudio se alinea con el itinerario de Sistemas Inteligentes, evidenciando las competencias del futuro profesional para diseñar, entrenar y evaluar arquitecturas de inteligencia artificial y visión por computador. A nivel institucional, dentro de la Universidad Nacional de Loja, el proyecto se enmarca en la línea de investigación "Industria, Innovación y Desarrollo Tecnológico"[17], cuyo propósito es generar propuestas que utilicen la inteligencia artificial, la computación y el control automático para elevar la competitividad y dar solución a problemas reales.

3. Objetivos

En esta sección se definen las metas fundamentales que guiarán el desarrollo de la investigación, orientadas a evaluar y comparar el rendimiento de los modelos YOLOv11n y YOLOv11s en el análisis de granos de maíz. A partir de un objetivo general centrado en la precisión y eficiencia computacional, se establecen objetivos específicos enfocados en la ingeniería de datos y el entrenamiento de modelos.

3.1. Objetivo General

Evaluar el nivel de precisión (precision, recall, mAP@0.5) y de eficiencia de inferencia (FPS) obtenido al ajustar y comparar los modelos YOLOv11n y YOLOv11s para la identificación, clasificación y conteo de granos de maíz sanos y con defectos superficiales, utilizando un dataset público de Roboflow Universe.

3.2. Objetivos Específicos

- Adaptar un dataset de imágenes de granos de maíz proveniente de Roboflow Universe a través de procesos de ingeniería de datos, con el fin de obtener un conjunto estructurado y apto para el entrenamiento y evaluación de los modelos YOLOv11n y YOLOv11s.
- Entrenar los modelos YOLOv11n y YOLOv11s en un entorno controlado mediante transferencia de aprendizaje y el ajuste de hiperparámetros para la identificación, clasificación y conteo de granos de maíz sanos y con defectos superficiales, evaluando su desempeño mediante el registro de métricas de precisión, recall, mAP@0.5 y tiempo de inferencia.

3.3. Alcance de proyecto

La definición del alcance establece los límites operativos, técnicos y metodológicos de esta investigación, adoptando como marco de trabajo las primeras cuatro fases de la metodología CRISP-ML(Q). El estudio abarcará estrictamente desde la **Fase 1 (Comprensión del Problema y de los Datos)** hasta la **Fase 4 (Evaluación del Modelo)**, vinculando estas etapas de forma directa con los objetivos específicos planteados. De este modo, las tareas de selección, análisis exploratorio y transformación del dataset público permitirán cumplir el primer objetivo específico, el cual se asocia directamente con la **Fase 1** y con la **Fase 2**

(Ingeniería de Datos). Por otra parte, el diseño experimental, la transferencia de aprendizaje y el ajuste de hiperparámetros englobados en la **Fase 3 (Ingeniería del Modelo)**, junto con la validación de las arquitecturas contemplada en la **Fase 4**, darán cumplimiento al segundo objetivo específico, limitando el proyecto a un entorno puramente experimental y controlado.

3.3.1. Fase 1(Objetivo Específico 1)

En este apartado se describen las actividades correspondientes a las fases de Comprensión y de Ingeniería de Datos de la metodología CRISP-ML(Q), abarcando desde la obtención del conjunto de imágenes hasta su estructuración final para el modelado.

Actividad 1: Adquisición y Análisis Exploratorio de Datos (EDA). Esta actividad inicial se centrará en la descarga e ingesta del conjunto de datos público sobre granos de maíz proveniente de Roboflow Universe. Posteriormente, se ejecutarán tareas de Análisis Exploratorio de Datos (EDA) para examinar la distribución de las clases (granos sanos frente a granos con defectos superficiales), verificar la integridad de las anotaciones de las cajas delimitadoras (bounding boxes) y analizar las resoluciones de las imágenes. Para el desarrollo de esta actividad se utilizará el lenguaje Python, empleando Pandas para la gestión de las anotaciones y Matplotlib para la visualización estadística de las distribuciones. El entregable producido al culminar esta actividad será el apartado del Análisis Exploratorio de Datos (EDA), el cuaderno de trabajo ejecutable (.ipynb) y el conjunto de datos original verificado en su integridad.

Actividad 2: Exploración de Técnicas de Ingeniería de Datos. El propósito de esta actividad será determinar qué transformaciones benefician realmente al conjunto de datos antes del entrenamiento. Las tareas a realizar consistirán en probar experimentalmente la viabilidad de implementar procesos de limpieza, estandarización de imágenes y normalización de píxeles. Asimismo, se considerará la ejecución de técnicas de balanceo de clases y aumento de datos (data augmentation) para evaluar si estas estrategias mejoran la robustez de la información. Las tecnologías a emplear para estas pruebas de transformación visual serán las librerías OpenCV y Albumentations. El entregable producido será la documentación de la justificación técnica sobre las transformaciones seleccionadas.

Actividad 3: Estructuración del Conjunto de Datos En esta actividad se aplicarán definitivamente las técnicas de ingeniería validadas en el paso anterior y se formateará la información. Las tareas principales incluirán la partición final de las imágenes y sus etiquetas en los subconjuntos estrictos de entrenamiento, validación y prueba (train/val/test), organizando las carpetas bajo la jerarquía exigida por los modelos YOLO. Para llevar a cabo esta reestructuración se utilizará Python junto con sus librerías nativas de manipulación de sistema (como os y shutil). El entregable final de esta fase será el Pipeline de preprocesamiento en código y el dataset estructurado en su versión final, listo para la ingesta en los modelos.

3.3.2. Fase 2(Objetivo Específico 2)

En este apartado se detallan las actividades correspondientes a las fases de Ingeniería del Modelo y Evaluación del Modelo de la metodología CRISP-ML(Q), abarcando la experimentación, entrenamiento y contraste empírico de los modelos.

Actividad 1: Configuración del Entorno y Diseño Experimental. Esta actividad establecerá el protocolo técnico previo al entrenamiento de los modelos YOLOv11n y YOLOv11s. Las tareas consistirán en configurar el entorno de ejecución local, habilitar la integración con servicios en la nube para procesos de alta demanda, y definir las bases de la transferencia de aprendizaje mediante la instanciación de los pesos preentrenados. Las tecnologías utilizadas incluirán el hardware local (CPU, 16 GB de RAM y GPU RTX 3060), la plataforma Google Colab, y el framework PyTorch mediante la API de Ultralytics. El entregable producido será el Script de configuración del entorno y carga inicial de las arquitecturas.

Actividad 2: Entrenamiento y Ajuste de Hiperparámetros. Esta actividad representará el núcleo experimental del proyecto. Las tareas consistirán en ejecutar el entrenamiento iterativo de las variantes YOLOv11n y YOLOv11s en el entorno controlado, realizando el ajuste empírico de hiperparámetros clave (tasa de aprendizaje, tamaño del lote o batch size, y número de épocas) para buscar la convergencia óptima en la identificación, clasificación y conteo de los granos. Este procesamiento intensivo se desarrollará utilizando los módulos de entrenamiento de Ultralytics apoyados en la aceleración de hardware (CUDA) proporcionada por PyTorch. El entregable consistirá en los Archivos de los modelos entrenados exportados en formato estándar (.pt) y los registros de configuración del entrenamiento.

Actividad 3: Evaluación Comparativa de Desempeño La actividad final medirá y contrastará la eficacia de ambos modelos. Las tareas incluirán la ejecución de inferencias utilizando el subconjunto de prueba reservado y el cálculo riguroso de las métricas establecidas: porcentaje de precisión (precision), recall, mAP@0.5 y el tiempo de inferencia (FPS), permitiendo determinar el equilibrio entre exactitud y eficiencia computacional. Se utilizarán las herramientas de validación integradas de Ultralytics junto con Matplotlib para la generación de gráficas de rendimiento comparativo. El entregable final será la documentación de los experimentos compuesto por las Tablas de métricas comparativas, las gráficas de validación y las conclusiones sobre la arquitectura de mejor rendimiento.

3.4. Limitaciones del proyecto

Las limitaciones de esta investigación se enmarcan principalmente en su alcance operativo, técnico y computacional. En primer lugar, el proyecto se circunscribe a un entorno puramente experimental y controlado, por lo que no se contempla el desarrollo de un sistema de software funcional, aplicativo web o móvil. En consecuencia, las etapas de despliegue en un entorno de producción, monitoreo y mantenimiento en tiempo real quedan excluidas del estudio. Asimismo, al depender exclusivamente de un conjunto de datos publico y estático, no se realizará recolección de muestras en campo. De igual manera, el rendimiento en la tarea de conteo estará condicionado a la disposición espacial de los granos en las imágenes del conjunto de datos, por lo que resolver escenarios extremos de alta densidad u oclusión severa (granos superpuestos) queda fuera del alcance de la optimización. Esto implica que la evaluación del rendimiento no considerará las variables dinámicas e impredecibles presentes en las líneas de procesamiento agroindustrial reales, tales como cambios drásticos de iluminación, alta velocidad de las bandas transportadoras, vibraciones de la cámara o la presencia de polvo y residuos externos, limitando la generalización del modelo a las condiciones exactas de las fotografías utilizadas.

Finalmente, desde la perspectiva técnica, el desarrollo de los experimentos estará condicionado por la infraestructura computacional disponible. A nivel local, el entrenamiento se ejecutará en una estación de trabajo provista de 16 GB de memoria RAM y un procesador gráfico NVIDIA RTX 3060 con 6 GB de memoria de video (VRAM). Esta capacidad de VRAM representa una limitación estricta para el entrenamiento de redes neuronales, ya que restringe la resolución máxima de las imágenes procesables y obliga a configurar tamaños de lote (batch size) reducidos, lo cual impacta directamente en el tiempo de ejecución y en la estabilidad de la convergencia del modelo. Para mitigar esta restricción, se integrará como soporte el entorno en la nube Google Colab, que permite el acceso bajo demanda a unidades de

procesamiento gráfico de mayor rendimiento. Sin embargo, la dependencia de esta plataforma introduce factores limitantes adicionales en la logística del proyecto, tales como tiempos máximos de sesión, interrupciones por inactividad, volatilidad del almacenamiento temporal y la necesidad de una conexión de red ininterrumpida. El estudio se enfoca prioritariamente en la viabilidad de arquitecturas ligeras bajo estos márgenes restrictivos de hardware, lo que, en conjunto con los antecedentes aportados por la bibliografía revisada, fundamenta la elección exclusiva de los modelos YOLOv11n y YOLOv11s frente a redes neuronales de mayor tamaño y complejidad.

3.5. Resumen del alcance del proyecto

Tabla I. Resumen de las actividades por cada objetivo.

Objetivo	Incluido en el objetivo	Excluido del objetivo	Entregable
O.G.	Ajuste y comparación de los modelos YOLOv11n y YOLOv11s.	Implementación o comparación con arquitecturas más pesadas (modelos de dos etapas o Transformers).	Modelos YOLOv11n y YOLOv11s ajustados y entrenados (.pt).
	Uso del dataset público estructurado de Roboflow Universe.	Validación práctica en líneas de procesamiento agroindustrial reales.	Código fuente y scripts de los experimentos (.py/.ipynb).
	Evaluación del equilibrio entre precisión y tiempo de inferencia (FPS).	Fases de monitoreo y mantenimiento continuo del modelo (etapas posteriores de CRISP-ML(Q)).	Sección de resultados y conclusiones integrado en el documento final.
O.E.1	Descarga, Análisis Exploratorio (EDA) y validación del dataset de Roboflow Universe.	Captura de imágenes fotográficas propias en campo o recolección de muestras físicas.	Cuaderno de trabajo ejecutable (.ipynb) y conjunto de datos original verificado.
	Exploración y evaluación experimental de la viabilidad de técnicas de ingeniería de datos (limpieza, estandarización, balanceo).	Etiquetado manual de imágenes en bruto desde cero y consideración de variables ambientales dinámicas.	Documentación de la justificación técnica sobre las transformaciones seleccionadas.
	Partición de la información bajo la jerarquía exigida por YOLO.	Incorporación de imágenes externas adicionales al dataset público seleccionado.	Pipeline de preprocesamiento en código y dataset estructurado final (train/val/test).
O.E.2	Configuración del entorno de ejecución local (RTX 3060), soporte en la nube (Google Colab) e instanciación de pesos preentrenados.	Configuraciones que excedan los 6 GB de VRAM local o dependan de sesiones ilimitadas en la nube.	Script de configuración del entorno y carga inicial de las arquitecturas.
	Entrenamiento iterativo de las variantes YOLOv11n y YOLOv11s con ajuste empírico de hiperparámetros usando PyTorch y CUDA.	Desarrollo de un sistema de software funcional, aplicaciones web, móviles o interfaces gráficas (UI).	Archivos de los modelos entrenados exportados (.pt) y registros de configuración.
	Ejecución de inferencias con el subconjunto de prueba para el cálculo de precisión, recall, mAP@0.5 y tiempo de inferencia.	Evaluación de escenarios extremos de alta densidad, oclusión severa, o condiciones con polvo y vibración.	Documentación de los experimentos, Tablas de métricas comparativas y conclusiones sobre la arquitectura de mejor rendimiento.

4. Metodología

En esta sección se describe la ejecución de la investigación estructurando el desarrollo del proyecto en tres dimensiones fundamentales. El *dónde* se establece en un entorno de experimentación híbrido, combinando una estación de trabajo local provista de aceleración gráfica (GPU RTX 3060) y el soporte en la nube mediante Google Colab para las tareas de mayor demanda computacional. El *cómo* rige la estructura de las actividades bajo las directrices de las primeras cuatro fases del ciclo de vida CRISP-ML(Q), abarcando estrictamente desde la comprensión inicial de los datos hasta la evaluación empírica de los modelos. Finalmente, el *con qué* hace referencia a la infraestructura tecnológica empleada, la cual se sustenta en el lenguaje Python y un ecosistema de librerías especializadas (tales como Pandas, OpenCV, Albumentations, PyTorch y la API de Ultralytics) para ejecutar el procesamiento de imágenes, el entrenamiento de las redes neuronales y el análisis comparativo.

4.1. Consideraciones éticas

La presente investigación se fundamenta de manera exclusiva en el uso de datos secundarios, empleando un conjunto de imágenes público de granos de maíz alojado en el repositorio de Roboflow Universe. Al tratarse de un conjunto de datos de acceso abierto, se establecen las siguientes directrices éticas:

- **Privacidad:** Dado que el conjunto de datos está compuesto por fotografías de material agrícola (granos de maíz), este carece por completo de Información de Identificación Personal. Al no involucrar sujetos humanos, registros médicos ni datos sensibles, se garantiza que no existe ningún riesgo de vulneración a la privacidad.
- **Licenciamiento:** Se ha verificado que el dataset se distribuye bajo la licencia *Creative Commons Attribution 4.0 International* (CC BY 4.0), la cual permite explícitamente su libre uso, adaptación y redistribución para fines académicos y de investigación. En estricto cumplimiento con esta normativa, se otorgará el crédito correspondiente citando de forma adecuada a los autores y recolectores originales de la información.
- **Integridad de la investigación:** Los datos y sus etiquetas originales no serán alterados de manera malintencionada para sesgar o inflar el rendimiento de los modelos. Las técnicas de ingeniería de datos (como limpieza, estandarización o aumento) se evaluarán y aplicarán bajo criterios estadísticos y técnicos rigurosos. Todo el procesamiento será

documentado de manera transparente para garantizar la reproducibilidad y la veracidad del análisis comparativo entre las arquitecturas YOLOv11n y YOLOv11s.

4.2. Resumen de la metodología

En la Tabla II se presenta la metodología aplicada en el presente proyecto de investigación. Este esquema detalla la articulación directa entre los objetivos específicos y las actividades prácticas a desarrollar, estructurándolas sistemáticamente bajo las primeras cuatro fases del marco de trabajo CRISP-ML(Q). Asimismo, el cuadro expone de forma clara los entregables concretos que se generarán al término de cada etapa, los enfoques técnicos empleados y el conjunto de herramientas o tecnologías.

Tabla II. Metodología aplicada al proyecto (Basada en CRISP-ML(Q)).

Objetivo	Actividades (Fases CRISP-ML(Q))	Entregables	Métodos/Técnicas	Herramientas/ Tecnologías
O.E.1	**Adquisición y Análisis Exploratorio de Datos (Fase 1)** Descarga, ingesta y visualización estadística de las clases y bounding boxes.	Cuaderno de trabajo ejecutable (.ipynb) y conjunto de datos original verificado.	CRISP-ML(Q): Comprensión de los Datos.	Entorno local, Python (Pandas, Matplotlib), Roboflow Universe.
	Exploración de Técnicas de Ingeniería de Datos (Fase 2) Pruebas de limpieza, estandarización, balanceo y data augmentation.	Documentación de la justificación técnica sobre las transformaciones seleccionadas.	CRISP-ML(Q): Ingeniería de Datos.	Entorno local, Python (OpenCV, Albumentations).
	Estructuración del Conjunto de Datos (Fase 2) Partición final de la información (train/val/test) bajo la jerarquía exigida.	Pipeline de preprocesamiento en código y dataset estructurado final.	CRISP-ML(Q): Ingeniería de Datos.	Entorno local, Python (librerías nativas: os, shutil).
O.E.2	**Configuración del Entorno y Diseño Experimental (Fase 3)** Configuración de la ejecución local/nube y bases de transferencia de aprendizaje.	Script de configuración del entorno y carga inicial de las arquitecturas.	CRISP-ML(Q): Ingeniería del Modelo.	Estación de trabajo local (CPU, RAM 16GB, GPU RTX 3060), Google Colab, PyTorch, Ultralytics.
	Entrenamiento y Ajuste de Hiperparámetros (Fase 3) Entrenamiento iterativo de YOLOv11n y YOLOv11s (ajuste de learning rate, batch size, épocas).	Archivos de los modelos entrenados exportados (.pt) y registros de configuración.	CRISP-ML(Q): Ingeniería del Modelo.	PyTorch con aceleración de hardware (CUDA), módulos de Ultralytics.
	Evaluación Comparativa de Desempeño (Fase 4) Medición rigurosa de precision, recall, mAP@0.5 y tiempo de inferencia (FPS).	Tablas, gráficas de validación y conclusiones documentadas en los resultados.	CRISP-ML(Q): Evaluación del Modelo.	Herramientas de validación de Ultralytics, Python (Matplotlib).

5. Marco Teórico

5.1. Fundamentos teóricos

5.1.1. Calidad y defectos en semillas de maíz

Evaluar la calidad de las semillas de maíz es vital para asegurar un buen rendimiento agrícola. Durante la cosecha y el procesamiento, los granos están expuestos a anomalías que comprometen su viabilidad, agrupándose principalmente en tres categorías: daños mecánicos (como roturas o grietas por la maquinaria), biológicos (deterioro por insectos o moho) y ambientales (como el daño por calor excesivo o germinación prematura) [19], [1]. El moho es especialmente crítico, ya que su desarrollo genera micotoxinas nocivas que reducen drásticamente la tasa de germinación y representan un grave riesgo sanitario [20], [4]. Tradicionalmente, la clasificación de semillas sanas y defectuosas se realiza mediante inspección visual humana, un proceso lento, ineficiente y propenso a errores por fatiga [2], [20]. Para solucionar esto, los algoritmos de detección de objetos como YOLO permiten analizar imágenes en tiempo real, identificando de forma rápida, precisa y no destructiva si una semilla presenta anomalías, incluso en escenarios complejos donde los granos están esparcidos densamente o en movimiento [3], [21].



Figura 1. Muestras de granos de maíz cosechados a máquina. (a) Granos enteros; (b) Granos quebrados; (c) Granos con moho; (d) Impurezas [21].

5.1.2. Inteligencia Artificial (IA)

La Inteligencia Artificial representa el esfuerzo interdisciplinario por replicar las capacidades cognitivas humanas en sistemas computacionales, permitiéndoles percibir su entorno, razonar y tomar decisiones. En lugar de ejecutar instrucciones rígidamente programadas, los sistemas de IA están diseñados para imitar la inteligencia humana en la resolución de problemas complejos. Dentro de este gran ecosistema, la IA actúa como el paraguas principal que alberga subdisciplinas más especializadas, fundamentales para comprender el avance de la visión por computador moderna [22]. En el contexto agroindustrial, la IA supone un cambio de

paradigma, ya que permite automatizar tareas que tradicionalmente dependían del agotador criterio visual humano, abriendo paso a evaluaciones mucho más objetivas y consistentes.

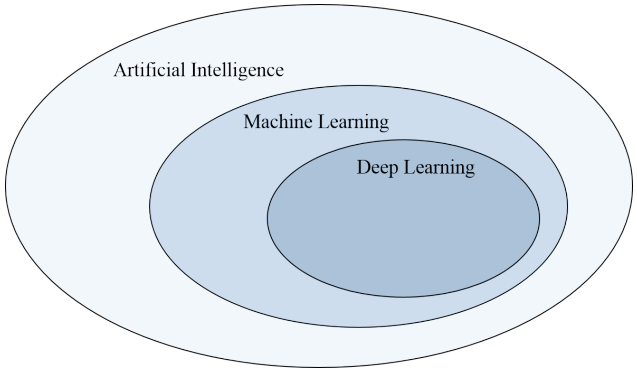


Figura 2. Organización y relación de la Inteligencia Artificial con el Aprendizaje Automático y Aprendizaje Profundo [22].

5.1.3. Machine Learning (ML)

Como un subcampo central de la IA, el Machine Learning o Aprendizaje Automático se basa en la premisa de que las máquinas pueden mejorar su desempeño autónomamente al ser expuestas a datos y experiencias pasadas, requiriendo una intervención humana mínima [22]. En lugar de ser programadas con reglas explícitas para cada tarea, los algoritmos de ML descubren patrones ocultos en bases de datos estructuradas [23]. Si bien el ML clásico utiliza modelos como árboles de decisión o máquinas de vectores de soporte (SVM) que han sido útiles en la agricultura [5], [23], su principal limitación radica en que necesita que un experto humano .^extraiga manualmente las características"de los datos antes de entrenar el modelo, lo cual es ineficiente cuando se trata de información muy compleja y de alta dimensionalidad, como las imágenes [22].

5.1.4. Deep Learning (DL)

El Deep Learning o Aprendizaje Profundo es una evolución del ML que ha revolucionado la forma en que las computadoras procesan datos complejos. Utilizando redes neuronales artificiales de múltiples capas ocultas, el DL simula la arquitectura lógica del cerebro humano para realizar extracciones de características de forma completamente automática [22], [23]. A diferencia del ML tradicional, el DL puede tomar datos crudos (como los miles de píxeles de una fotografía) y, capa por capa, aprender representaciones cada vez más abstractas sin requerir que un humano le indique qué buscar. Esta capacidad de aprendizaje de extremo a extremo

(end-to-end) lo ha convertido en la tecnología preferida para abordar las complejidades del mundo real en el análisis de imágenes [22], [12].

5.1.5. Visión por Computador

La Visión por Computador es la disciplina que integra a las CNN para capacitar a los sistemas informáticos con la habilidad de percibir, comprender e interpretar el mundo visual con un alto grado de precisión [22], [24]. Este campo busca que la máquina no solo "vea" una imagen, sino que extraiga información semántica y tome decisiones basadas en ella. En el contexto agroindustrial, la visión por computador representa un salto cualitativo al reemplazar las evaluaciones visuales humanas por un escrutinio automatizado, objetivo y extremadamente rápido, facilitando aplicaciones de robótica, monitoreo en tiempo real y clasificación automática de cultivos [8], [24].

5.1.6. Detección de Objetos

Avanzando un paso más allá de la simple clasificación de imágenes que solo indica qué hay en una imagen de forma global, la Detección de Objetos tiene el doble propósito de identificar las categorías de los elementos y localizarlos exactamente en el espacio mediante cajas delimitadoras (bounding boxes) [22], [24]. Históricamente, han existido enfoques de dos etapas que son muy precisos, pero lentos computacionalmente; sin embargo, en entornos industriales se requiere velocidad [8]. Aquí surge la familia de algoritmos YOLO (You Only Look Once), que procesa la imagen en una única evaluación o pasada, logrando un equilibrio excepcional entre alta precisión y velocidad de inferencia en tiempo real [9].



Figura 3. Proceso de la deteccion de objetos en una imagen [24].

5.1.7. Redes Neuronales Convolucionales (CNN)

Dentro del Deep Learning, las Redes Neuronales Convolucionales son la arquitectura estándar y más exitosa para analizar y percibir información visual [8]. Estas redes están diseñadas específicamente para procesar imágenes mediante el uso de "filtros" o núcleos de convolución que se deslizan sobre la imagen, extrayendo características espaciales de manera jerárquica [23], [19]. En las primeras capas, una CNN puede detectar elementos básicos como bordes y colores, mientras que en capas más profundas logra combinar estos elementos para reconocer texturas, formas geométricas y partes completas de un objeto [25]. Gracias a mecanismos como el "pooling"(agrupación), las CNN reducen la dimensionalidad espacial de los datos sin perder información crítica, logrando una eficiencia computacional que las hace el estándar ideal para la visión artificial [19], [23].

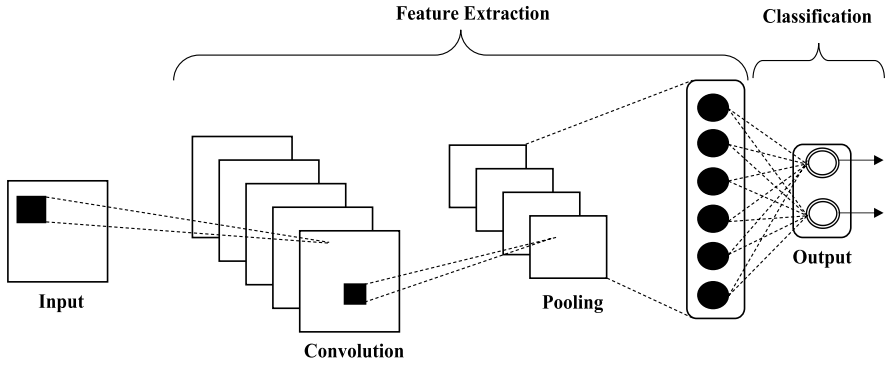


Figura 4. Arquitectura de una CNN con una capa convolucional, una capa de agrupación (Pooling) y una capa totalmente conectada [23].

5.2. Modelos, métodos y técnicas

5.2.1. Arquitecturas de detección de una sola etapa (One-stage detectors)

Las arquitecturas de detección de objetos se dividen tradicionalmente en dos enfoques, siendo los detectores de una sola etapa (One-stage detectors) los más eficientes para aplicaciones tecnológicas dinámicas [8], [26]. A diferencia de los modelos de dos etapas (como la familia R-CNN) que primero generan múltiples propuestas de regiones y luego las clasifican de forma secuencial, los detectores de una etapa unifican este proceso en su totalidad [24], [27]. Tratan la detección como un problema de regresión directo, procesando los píxeles de la imagen en una única evaluación (pasada) a través de la red neuronal para predecir simultáneamente las coordenadas espaciales de las cajas delimitadoras y sus respectivas probabilidades de clase [8], [27].

Esta simplificación arquitectónica reduce drásticamente la carga computacional y la latencia del modelo, permitiendo velocidades de inferencia muy rápidas sin sacrificar significativamente la exactitud. Por esta razón, el enfoque de una sola etapa es altamente preferido para entornos industriales o agrícolas donde se requiere analizar múltiples objetos en movimiento continuo, en tiempo real y frecuentemente utilizando hardware con recursos limitados [8], [24].

5.2.2. Familia YOLO (You Only Look Once)

La familia de algoritmos YOLO (You Only Look Once) es el exponente más destacado y exitoso dentro de los detectores de una sola etapa, introducido originalmente en 2015 [26]. Su principio fundamental consiste en superponer una cuadrícula (grid) sobre la imagen de entrada; si el centro de un objeto cae dentro de una celda específica, dicha celda se vuelve directamente responsable de predecir las cajas delimitadoras y las puntuaciones de confianza que indican la probabilidad de que el objeto esté ahí [8]. Esta visión global le permite a YOLO comprender el contexto general de la imagen, reduciendo significativamente los errores de falsos positivos en los fondos en comparación con otros métodos [27]. Con el paso de los años, YOLO ha evolucionado a través de múltiples versiones (desde YOLOv1 hasta arquitecturas recientes como YOLOv11 y v12), incorporando redes de extracción de características cada vez más profundas, mecanismos de atención visual y módulos de fusión de datos optimizados [26]. Estas mejoras continuas han logrado perfeccionar el equilibrio entre una altísima precisión analítica y la velocidad extrema requerida para el procesamiento en tiempo real, consolidando a YOLO como el estándar de facto en sectores de automatización [26], [24].

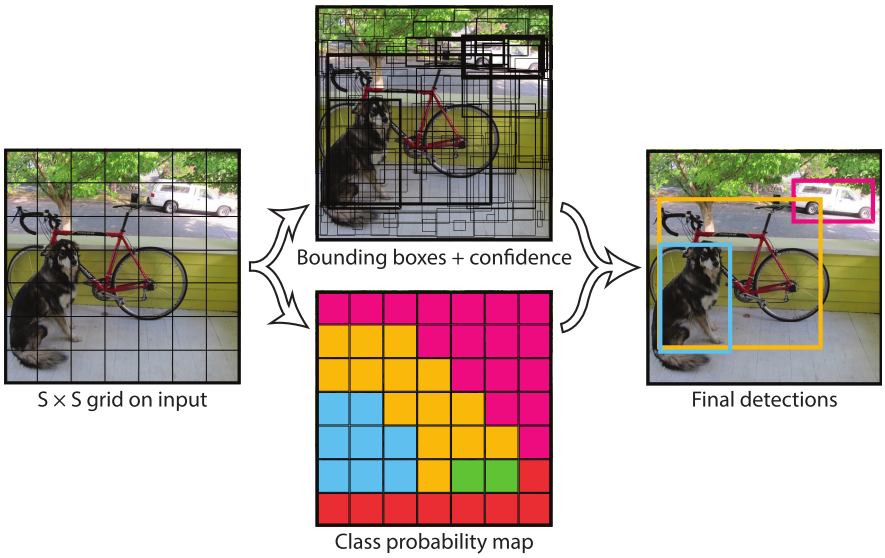


Figura 5. Deteccion de objetos con YOLO [27].

5.2.3. Metodología CRISP-ML(Q)

El desarrollo de sistemas basados en aprendizaje automático requiere marcos de trabajo estructurados para garantizar su fiabilidad técnica y comercial. La metodología CRISP-ML(Q) (Cross-Industry Standard Process model for the development of Machine Learning applications with Quality assurance) nace como una evolución del clásico estándar de minería de datos CRISP-DM, adaptado de manera específica a los ciclos de vida de los modelos predictivos. Este modelo abarca seis fases iterativas e interconectadas: la comprensión conjunta del negocio y los datos, la preparación de la información, el modelado, la evaluación del sistema, su despliegue y, finalmente, su monitoreo y mantenimiento [28].

Estas fases se estructuran de la siguiente manera:

- **Comprensión del negocio y los datos:** En esta etapa se definen los objetivos comerciales y se traducen en objetivos de aprendizaje automático, se recolectan los datos, se verifica su calidad y se evalúa la viabilidad general del proyecto [28].
- **Preparación de la información:** Su propósito es producir un conjunto de datos óptimo para la fase de modelado mediante tareas como la selección de características, la limpieza de ruido, la construcción de nuevos datos (como el aumento de datos) y la estandarización o normalización [28].
- **Modelado:** Se seleccionan y entrenan los algoritmos para crear uno o varios modelos que satisfagan los requisitos y restricciones del proyecto, asegurando que los métodos empleados y los resultados obtenidos sean estrictamente reproducibles [28].
- **Evaluación del sistema:** Consiste en validar el rendimiento y determinar la robustez del modelo frente a datos no vistos (como en un conjunto de prueba ciego), comparando los resultados con los criterios de éxito previamente definidos para decidir si es apto para producción [28].
- **Despliegue:** Implica la integración del modelo en su entorno de aplicación práctica, definiendo el hardware de inferencia necesario, evaluando su comportamiento en condiciones de producción y estableciendo una estrategia de implementación segura [28].
- **Monitoreo y Mantenimiento:** Se vigila continuamente el rendimiento del modelo a lo largo del tiempo, ya que la distribución de los datos reales suele cambiar. Esta fase evalúa el desgaste del modelo y determina cuándo es necesario actualizarlo o reentrenarlo con nueva información para evitar predicciones erróneas [28].

La innovación principal de CRISP-ML(Q) radica en dos pilares: primero, la inclusión de la fase de monitoreo y mantenimiento continuo, vital debido a que los modelos de inteligencia artificial tienden a degradar su rendimiento cuando se enfrentan a un entorno real que cambia con el tiempo. Segundo, integra rigurosos métodos de Aseguramiento de la Calidad (Quality Assurance - Q) en cada etapa. Este aseguramiento se basa en identificar y mitigar riesgos técnicos de forma preventiva, garantizando que el modelo sea robusto, reproducible y cumpla plenamente las expectativas antes y después de salir a producción [28].

5.2.4. Transferencia de Aprendizaje (Transfer Learning)

La transferencia de aprendizaje es una técnica de aprendizaje profundo que consiste en reutilizar modelos de redes neuronales previamente entrenados (generalmente en grandes conjuntos de datos públicos como ImageNet o COCO) y aplicarlos para resolver un problema nuevo y específico [22], [7], [23]. Al emplear este método, el modelo transfiere el conocimiento previamente adquirido, como la capacidad de identificar formas, bordes y patrones visuales básicos, a la nueva tarea [22], [6]. Su mayor ventaja radica en que acelera notablemente la convergencia del modelo, ahorra tiempo de entrenamiento y minimiza el uso de recursos computacionales,. Este enfoque se ha vuelto fundamental en la visión por computadora para la agricultura, ya que reduce la dependencia de conjuntos de datos masivos y etiquetados, permitiendo crear sistemas robustos (como detectores de semillas o enfermedades) incluso cuando la cantidad de imágenes disponibles es escasa [22], [5].

5.2.5. Ajuste Fino (Fine-Tuning)

El ajuste fino es el proceso mediante el cual un modelo preentrenado se adapta y optimiza de forma precisa utilizando el conjunto de datos particular del nuevo proyecto [22], [23]. En la práctica, implica tomar una arquitectura que ya posee conocimiento general (como Xception, VGG16 o modelos de la serie YOLO) y someterla a un entrenamiento adicional con los datos específicos de la tarea objetivo [6], [26]. Durante este proceso, los pesos y parámetros internos de la red neuronal se recalibran para aprender las sutilezas, detalles y particularidades exactas de la nueva información, como las diferencias visuales entre un grano de maíz sano y uno defectuoso [23], [6]. Esta técnica es crucial para lograr una precisión extremadamente alta en aplicaciones especializadas, evitando el inmenso coste que supondría entrenar una red compleja desde cero [6].

5.2.6. Técnicas de Ingeniería de Datos

La ingeniería de datos comprende un conjunto de estrategias aplicadas durante el preprocesamiento para garantizar que la información que alimenta al modelo sea íntegra, representativa y libre de ruidos. En la visión artificial, estas técnicas incluyen tareas de estandarización, como el redimensionamiento de las imágenes, conversiones de espacios de color y aplicación de filtros para reducir la interferencia visual o resaltar las texturas [12], [29]. Al trabajar con granos pequeños en escenarios de alta densidad, limpiar los datos base es vital para no confundir al modelo [19], [30].

5.2.7. Aumento de datos (Data Augmentation)

Un pilar de la ingeniería de datos es el aumento de datos. Esta técnica incrementa artificialmente la diversidad y el tamaño del conjunto de entrenamiento mediante transformaciones espaciales (rotaciones, recortes, volteos) y manipulaciones de intensidad (ajustes de brillo, contraste, adición de ruido gaussiano) [1], [12]. Aplicar estas variaciones asegura que el modelo se vuelva invariante a los cambios de iluminación o a la orientación aleatoria en la que pueden encontrarse las semillas de maíz en un entorno real, fortaleciendo significativamente su capacidad de generalización ante datos no vistos [11].

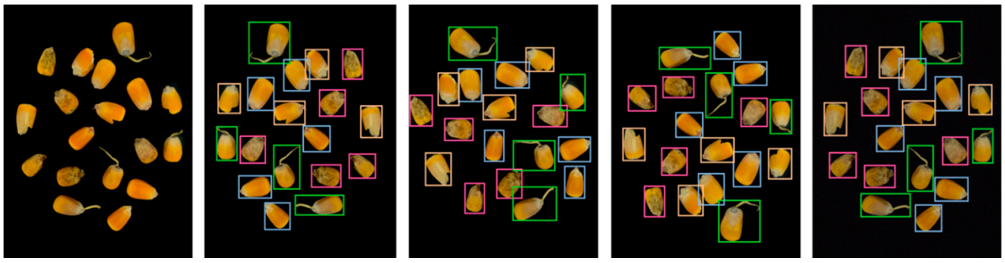


Figura 6. Ejemplo de aumento de datos aplicando rotaciones, volteos y ruido gaussiano [1].

5.2.8. Métricas de Evaluación

Para determinar si un modelo de detección de objetos (como las variantes de YOLO) es verdaderamente efectivo y apto para ser implementado en un entorno real, no basta con la observación visual; es indispensable cuantificar su desempeño mediante métricas matemáticas rigurosas [6]. Estas métricas nos permiten evaluar tanto la exactitud del modelo al identificar y localizar los objetos, como su velocidad de procesamiento computacional [6] [25]. Estas evaluaciones se construyen a partir de conceptos fundamentales de la matriz de confusión:

Verdaderos Positivos (TP - identificaciones correctas), Falsos Positivos (FP - detecciones erróneas donde no hay objeto) y Falsos Negativos (FN - objetos reales que el modelo ignoró) [19], [6].

- **Precisión (Precision):** Evalúa la exactitud de las predicciones positivas del modelo. En otras palabras, de todos los objetos que el modelo detectó y clasificó como una categoría específica, responde a cuántos eran realmente correctos. Un valor alto significa que el modelo genera muy pocos falsos positivos [11], [3].

$$\text{Precision} = \frac{TP}{TP + FP} \tag{1}$$

  (Donde TP son los Verdaderos Positivos y FP los Falsos Positivos [19]).

- **Sensibilidad o Recuperación (Recall):** Mide la capacidad del modelo para encontrar y detectar todos los objetos reales presentes en una imagen. Si el Recall es alto, significa que el modelo casi no deja objetos sin detectar (pocos falsos negativos) [11], [3].

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2}$$

  (Donde FN son los Falsos Negativos).

- **mAP@0.5 (Mean Average Precision):** Es una de las métricas de rendimiento más importantes y completas en las tareas de detección de objetos, ya que proporciona un indicador global de la precisión del modelo evaluando simultáneamente todas las categorías [6], [20]. El cálculo del mAP se realiza en dos etapas. Primero, se obtiene el *Average Precision* (AP) para cada categoría individual calculando el área bajo la curva formada por la Precisión y el Recall (curva P-R) [6], [29]. Una vez que se tiene el AP de cada clase, se suman todos estos valores y se dividen por el número total de clases para obtener el promedio general [11]. El indicador "@0.5" significa que, para que el modelo considere que detectó un objeto correctamente (Verdadero Positivo), la superposición (*Intersection over Union* - IoU) entre la caja delimitadora predicha y la caja real del objeto debe ser igual o superior al 50 % [20].

  Fórmula del AP (para una clase específica i):

$$\text{AP}_i = \int_0^1 P_i(R_i) dR_i \tag{3}$$

  (Donde P es Precisión y R es Recall).

Fórmula del mAP:

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^{N} \text{AP}_i \tag{4}$$

(Donde N es el número total de clases y AP_i es la precisión promedio de cada clase calculada anteriormente).

- **FPS (Frames Per Second) o Tiempo de Inferencia:** Mide la eficiencia y velocidad del modelo en entornos operativos. Representa la cantidad de imágenes que la arquitectura es capaz de procesar por segundo [1], [6], [10]. Para aplicaciones en tiempo real o dispositivos de hardware limitado, un alto FPS y un bajo tiempo de inferencia son tan críticos como una buena precisión.

$$\text{FPS} = \frac{1}{t} \quad \text{o} \quad \text{FPS} = \frac{\text{Número de Frames}}{\text{Tiempo transcurrido}} \tag{5}$$

(Donde t es el tiempo de detección de una sola imagen).

5.3. Trabajos relacionados

En esta sección se presenta una revisión de la literatura científica reciente relacionada con la identificación, clasificación y conteo de semillas de maíz utilizando técnicas de Machine Learning y Deep Learning. Se destacan especialmente los estudios que emplean diversas versiones de la arquitectura YOLO, analizando sus metodologías, los resultados obtenidos en precisión y velocidad de inferencia, y cómo sus hallazgos fundamentan o difieren de los objetivos del presente proyecto basado en YOLOv11. En la Tabla III se presenta un resumen de los trabajos relacionados.

Tabla III. Resumen de trabajos relacionados.

ID	Título	Referencia
TR1	An improved YOLOv8 model for detecting damage types of maize kernels using proximal hyperspectral imaging	[20]
TR2	Detection of surface defects for maize seeds based on YOLOv5	[19]
TR3	Early Detection of Surface Mildew in Maize Kernels Using Machine Vision Coupled with Improved YOLOv5 Deep Learning Model	[4]
TR4	LWCD-YOLO: A Lightweight Corn Seed Kernel Fast Detection Algorithm Based on YOLOv11n	[29]
TR5	Maize Grain Classification Using Machine Learning	[14]
TR6	Maize Kernel Batch Counting System Based on YOLOv8-ByteTrack	[11]
TR7	Maize Kernel Quality Detection Based on Improved Lightweight YOLOv7	[1]
TR8	Maize Seed Damage Identification Method Based on Improved YOLOV8n	[3]
TR9	Real-Time Detection Technology of Corn Kernel Breakage and Mildew Based on Improved YOLOv5s	[21]
TR10	Real-Time Detection of Varieties and Defects in Moving Corn Seeds Based on YOLO-SBWL	[2]
TR11	Research on a Lightweight Method for Maize Seed Quality Detection Based on Improved YOLOv8	[9]
TR12	Soft X-ray image recognition and classification of maize seed cracks based on image enhancement and optimized YOLOv8 model	[30]
TR13	A Systematic Review of Machine Learning based Classification and Prediction Models for Grains (Maize)	[5]
TR14	High accuracy identification of maize seed varieties based on a lightweight improved YOLOv8	[6]
TR15	Development of Deep Learning Methodology for Maize Seed Variety Recognition Based on Improved Swin Transformer	[13]

El trabajo TR1 propone un modelo YOLOv8 que integra imágenes hiperespectrales y atención SCSA (97.7 % de precisión y 0.982 de mAP). Aunque difiere del enfoque RGB del presente proyecto, valida la capacidad de las versiones YOLO modernas para discriminar defectos sutiles mediante la fusión de características espaciales [20].

El TR2 presenta un YOLOv5S aligerado con MobileNet y ECA (92.8 % de precisión, 8.8 MB).

Este artículo aporta la demostración de que aligerar la arquitectura reduce los requisitos de hardware sin una caída drástica en la precisión, justificando directamente la evaluación de las versiones "nano"(v11n) y "small"(v11s) [19].

En el TR3, un YOLOv5s mejorado con ShuffleNet y CBAM detecta moho de forma temprana (mAP50 de 0.955, 2.4 MB). Su relevancia radica en confirmar que los modelos ligeros son altamente efectivos para clasificar patologías superficiales en tiempo real [4].

El trabajo TR4 introduce LWCD-YOLO, basado directamente en YOLOv11n, logrando un mAP50 del 99.49 % y 280 FPS con apenas 1.27M de parámetros. Es el antecedente de mayor aporte al proyecto, ya que establece un *baseline* contemporáneo sobre el rendimiento superior de YOLOv11n en la detección de granos de maíz [29].

El TR5 aborda la clasificación mediante un marco híbrido (YOLO, U2-Net y SVM), logrando un 95 % de precisión. Su principal contribución es visibilizar los retos de variación de fondo y superposición en los datasets de Roboflow, contrastando con la solución directa (*end-to-end*) propuesta con YOLOv11 [14].

En cuanto al TR6, los autores desarrollaron un sistema dinámico de conteo integrando YOLOv8 y ByteTrack (precisión mayor a 99 %). Este estudio es fundamental para el objetivo de conteo del proyecto, evidenciando que el *tracking* previene el conteo duplicado y mitiga los problemas de oclusión en movimiento [11].

El TR7 propone YOLOv7-MEF empleando YOLOv7-tiny y MobileNetV3 (98.94 % de precisión a 76.92 FPS). Consolida la premisa de buscar un equilibrio óptimo entre precisión y velocidad de inferencia, ideal para futuros despliegues en hardware agrícola con recursos limitados [1].

El estudio TR8 evalúa el modelo OBW-YOLO (YOLOv8n) en semillas esparcidas aleatoriamente en alta densidad (93.6 % de precisión). Aporta una advertencia crítica sobre la pérdida de eficacia ante la oclusión severa, un factor que deberá analizarse rigurosamente al evaluar a YOLOv11 [3].

El TR9 mejora YOLOv5s con atención CBAM y una cabeza Transformer (96.1 % de mAP para roturas y moho). Fundamenta teóricamente cómo la atención multiescala mejora la clasificación de defectos visualmente similares, respaldando la capacidad de extracción de características nativa de YOLOv11 [21].

El trabajo TR10 desarrolla YOLO-SBWL aplicando compresión (poda LAMP), disminuyendo su tamaño un 67.21 % para lograr inferencias de 11 ms con 97.21 % de mAP. Demuestra que la compresión favorece el tiempo de inferencia sin sacrificar exactitud, un criterio central

en la evaluación comparativa [2].

El TR11 optimiza YOLOv8 para objetos pequeños mediante SPD-Conv (98.5 % de mAP a 163.9 FPS). Confirma que evitar la pérdida de información de grano fino es vital, estableciendo un alto estándar de FPS contra el cual se medirá el rendimiento de YOLOv11n/s [9].

En el TR12, se detectan grietas internas usando rayos X y YOLOv8s (99.66 % de precisión). Si bien la captura difiere del espectro visible, valida la robustez arquitectónica de las versiones "small"(s) de YOLO para localizar anomalías minúsculas [30].

El TR13 corresponde a una revisión sistemática que concluye que la ingeniería de datos y la calidad del dataset son más determinantes que el tamaño del algoritmo. Este hallazgo valida fuertemente la importancia de la fase de preparación de datos planteada en los objetivos del proyecto [5].

El TR14 implementa E-YOLOv8 con FasterNet (96.2 % de mAP y 114.9 FPS). Subraya que las versiones estándar contienen cálculos redundantes, lo que justifica la comparación directa entre el modelo base "nano" y el "small" para evaluar cuál ofrece el mejor costo-beneficio computacional [6].

Finalmente, el TR15 utiliza Swin Transformer (MFSwin) para identificar variedades, alcanzando un 96.53 % de precisión. Provee un excelente marco comparativo externo, consolidando la hipótesis de que YOLOv11 ofrecerá un balance superior frente al alto costo paramétrico de los modelos Transformer [13].

5.4. Aporte del marco teórico al proyecto

El marco teórico estructurado proporciona el fundamento conceptual y técnico necesario para evaluar el rendimiento de arquitecturas de detección de objetos en el control de calidad de semillas de maíz. La revisión de la Visión por Computador y las Redes Neuronales Convolucionales valida que los detectores de una sola etapa (one-stage detectors) de la familia YOLO son idóneos para entornos agroindustriales al lograr un equilibrio entre alta precisión y velocidad de inferencia. Específicamente, el análisis de la literatura consolida la decisión de emplear las variantes ligeras YOLOv11n y YOLOv11s. Como se verificó en TR4, la arquitectura base en su versión nano ofrece un punto de partida adecuado para la detección rápida de semillas. Asimismo, la revisión de estudios como TR2, TR7 y TR14 muestra que los modelos ligeros reducen drásticamente la redundancia computacional sin comprometer gravemente la exactitud analítica. Esta aproximación metodológica responde de forma técnica y estratégica

a las restricciones de infraestructura del proyecto, garantizando que el entrenamiento sea estable y viable al ejecutarse en una GPU local NVIDIA RTX 3060 con un límite estricto de 6 GB de memoria VRAM. Con base en esto, se justifica el descarte de arquitecturas con un alto costo paramétrico o enfoques basados en Transformers, como el expuesto en TR15.

El análisis de los trabajos relacionados también orienta el abordaje de los desafíos propios del procesamiento de imágenes en la Fase 2 de la metodología CRISP-ML(Q). El estudio TR13 concluye que las técnicas de ingeniería de datos y la calidad del conjunto de datos suelen ser más determinantes para el rendimiento del modelo que el incremento en el tamaño del algoritmo. Por su parte, en TR8 se visualizó la pérdida de eficacia predictiva ante situaciones de oclusión severa y alta densidad de granos. Atendiendo a estos antecedentes, el proyecto no asume transformaciones visuales definitivas desde el inicio, sino que propone explorar experimentalmente qué técnicas benefician realmente la robustez de la información. Se evaluará la viabilidad de implementar procesos de limpieza, estandarización y normalización de píxeles empleando librerías como OpenCV y Albumentations. De igual forma, al probar estrategias de aumento de datos (data augmentation) y balanceo de clases, la experimentación considerará equilibrar las instancias de etiquetas (label instances) representadas para los granos sanos y defectuosos, en lugar de centrarse únicamente en el número de imágenes, buscando mitigar posibles sesgos analíticos de manera totalmente empírica antes del entrenamiento.

Finalmente, la sistematización de las métricas de evaluación establece un enfoque cuantitativo y riguroso para la investigación. La integración de métricas matemáticas como la precisión, sensibilidad (recall), mAP@0,5 y el tiempo de inferencia en FPS, ampliamente validadas en estudios como el TR11 y TR14, resultan indispensables para cuantificar el desempeño de los modelos. En conjunto, este marco teórico no solo orienta la logística de preprocesamiento y entrenamiento, sino que garantiza que el proceso final de evaluar y contrastar ambas arquitecturas aporte evidencia empírica clara, reproducible y coherente con las necesidades del sector agrícola.

6. Cronograma de actividades

El desarrollo metodológico de este proyecto de integración curricular se planifica de forma sistemática para completarse en un periodo continuo de 16 semanas. La distribución temporal se fundamenta en las primeras cuatro fases de la metodología CRISP-ML(Q) descritas en el alcance.

La planificación se divide en dos fases principales que corresponden de manera directa a los objetivos específicos del estudio:

- **Fase 1: Ingeniería de Datos (Semanas 1 a 6):** Dedicada al cumplimiento del Primer Objetivo Específico. Comprende la ingesta y el Análisis Exploratorio de Datos (EDA) para evaluar la calidad visual e integridad de las anotaciones (semanas 1 y 2); la exploración experimental de técnicas de limpieza, balanceo por instancias de etiquetas y aumento de datos mediante OpenCV y Albumentations (semanas 3 y 4); y la partición y estructuración jerárquica definitiva del dataset bajo el formato exigido por YOLO (semanas 5 y 6).
- **Fase 2: Modelado y Evaluación (Semanas 7 a 16):** Enfocada en el cumplimiento del Segundo Objetivo Específico. Inicia con la configuración técnica del entorno local (RTX 3060) y de soporte en la nube junto con el diseño experimental previo (semanas 7 y 8). Posteriormente, se ejecuta el bloque de procesamiento intensivo para el entrenamiento iterativo y ajuste de hiperparámetros (tasa de aprendizaje, tamaño de lote, épocas, etc.) de las variantes YOLOv11n y YOLOv11s (semanas 9 a 12). Finalmente, las semanas 13 a 16 se destinan a la evaluación comparativa mediante métricas globales (precisión, recall, mAP@0.5 y FPS) sobre el conjunto de prueba, integrando el análisis estadístico y las conclusiones en el documento final.

A continuación, en la Tabla IV, se detalla la secuencialidad y duración estimada para cada actividad programada.

Tabla IV. Cronograma detallado de actividades por semanas.

Actividades	**Semana 1**	**Semana 2**	**Semana 3**	**Semana 4**	**Semana 5**	**Semana 6**	**Semana 7**	**Semana 8**	**Semana 9**	**Semana 10**	**Semana 11**	**Semana 12**	**Semana 13**	**Semana 14**	**Semana 15**	**Semana 16**
Objetivo Específico 1																
1.1. Adquisición y Análisis Exploratorio de Datos (EDA).																
1.2. Exploración de Técnicas de Ingeniería de Datos.																
1.3. Estructuración del Conjunto de Datos.																
Objetivo Específico 2																
2.1. Configuración del Entorno y Diseño Experimental.																
2.2. Entrenamiento y Ajuste de Hiperparámetros.																
2.3. Evaluación Comparativa de Desempeño.																

7. Presupuesto y financiamiento

La ejecución del presente proyecto de investigación conlleva una serie de gastos operativos y la valoración económica de los recursos empleados. A continuación, se detalla la estructura de costos estimada, la cual abarca tanto los aportes valorados (talento humano y equipo de cómputo propio) como los gastos directos necesarios (servicios en la nube y conectividad) para el entrenamiento y evaluación de los modelos de Deep Learning.

7.1. Talento humano

Este rubro representa la valoración económica del tiempo intelectual y técnico dedicado a la investigación. Para el estudiante investigador, el costo por hora ($6,25 USD) se ha estimado tomando como referencia directa las tarifas del mercado de desarrollo tecnológico en Latinoamérica (Chile) para un perfil de *Ingeniero/a de Machine Learning Junior*[1], considerando una tasa de dedicación de tiempo completo equivalente a la base del rango salarial ofrecido de $1.000,00 USD mensuales.

La adopción de esta referencia salarial se justifica en el cumplimiento de las exigencias técnicas del rol, las cuales se alinean directamente con las competencias aplicadas en este proyecto. Específicamente, el desarrollo de la investigación requiere el dominio del lenguaje Python y la implementación de modelos predictivos utilizando librerías avanzadas de Machine Learning como PyTorch. Adicionalmente, el rigor metodológico del trabajo exige el uso continuo de Git para el control de versiones y garantizar la calidad del código, cubriendo así el perfil tecnológico estipulado por la industria. Asimismo, se cuantifican las horas de acompañamiento y revisión por parte del Director del Trabajo de Integración Curricular, conforme a la Tabla V.

Tabla V. Presupuesto de Talento Humano

Descripción	**Cantidad**	**Unidad**	**Valor Unitario**	**Valor Total**
Estudiante investigador	360	Hora	$6,25	$2.250,00
Director de TIC	16	Hora	$10,48	$167,68
			Total	**$2.417,68**

[1]Referencia salarial basada en la oferta laboral para Ingeniero/a de Machine Learning Junior en Suncast a través de Get on Board.

7.2. Servicios

Corresponde a los gastos operativos recurrentes necesarios para garantizar el flujo de conectividad, los trámites legales de titulación (firma electrónica) y las herramientas de apoyo basadas en inteligencia artificial. La suscripción a Google Colab Pro se limita estrictamente a 2 meses, debido a que el pipeline inicial de ingeniería de datos y la experimentación base se ejecutan localmente, reservando las unidades de procesamiento en la nube exclusivamente para las fases de entrenamiento masivo y ajuste intensivo de hiperparámetros, como se detalla en la Tabla VI.

Tabla VI. Presupuesto de Servicios

Descripción	Cantidad	Unidad	Valor Unitario	Valor Total
Internet de banda ancha	4	Meses	$22,00	$88,00
Firma electrónica	1	Licencia	$20,00	$20,00
Suscripción Google AI Pro	4	Meses	$20,00	$80,00
Suscripción Google Colab Pro	2	Meses	$10,00	$20,00
			Total	**$208,00**

7.3. Hardware

En esta categoría se cuantifica la amortización y uso del equipo de cómputo personal empleado como estación de trabajo local para las fases de análisis exploratorio (EDA), preprocesamiento de imágenes y experimentación base de los modelos YOLO, como se detalla en la Tabla VII.

Tabla VII. Presupuesto de Hardware

Descripción	Cantidad	Unidad	Valor Unitario	Valor Total
Laptop MSI Pulse GL66 (CPU: Intel Core i7-11800H, RAM: 16 GB, GPU: NVIDIA RTX 3060 6GB)	1	Equipo	$1.200,00	$1.200,00
			Total	**$1.200,00**

7.4. Software

Se describen las herramientas lógicas y los entornos de desarrollo requeridos. El proyecto se apoya fuertemente en el ecosistema de código abierto (*Open Source*), lo que permite reducir

los costos de desarrollo a cero. El entorno de programación principal, Antigravity IDE, se encuentra incluido dentro de los beneficios de la suscripción mensual a Google AI Pro declarada en la sección de servicios.

Tabla VIII. Presupuesto de Software

Descripción	Cantidad	Unidad	Valor Unitario	Valor Total
Antigravity IDE (Vía Google AI Pro)	1	Licencia	$0,00	$0,00
Framework PyTorch & Ultralytics	1	Licencia	$0,00	$0,00
Librerías Python (OpenCV, Pandas)	1	Licencia	$0,00	$0,00
Git	1	Licencia	$0,00	$0,00
			Total	**$0,00**

7.5. Resumen del presupuesto

La Tabla IX consolida los valores parciales de cada rubro calculado anteriormente. Para asegurar la viabilidad financiera ante posibles fluctuaciones tecnológicas o necesidades de recursos adicionales, se ha incluido un margen del 10 % destinado a gastos imprevistos, estableciendo así el costo total referencial del proyecto.

Tabla IX. Resumen del presupuesto general

Descripción	Valor
Talento Humano	$2.417,68
Servicios	$208,00
Hardware	$1.200,00
Software	$0,00
Subtotal	**$3.825,68**
Imprevistos (10 %)	$382,57
Total general	**$4.208,25**

8. Bibliografía

[1] L. Yang, C. Liu, C. Wang y D. Wang, "Maize Kernel Quality Detection Based on Improved Lightweight YOLOv7," en, *Agriculture*, vol. 14, n.º 4, pág. 618, abr. de 2024, ISSN: 2077-0472. DOI: 10.3390/agriculture14040618

[2] Y. Che, H. Bai, L. Sun, Y. Fang, X. Guo y S. Yin, "Real-Time Detection of Varieties and Defects in Moving Corn Seeds Based on YOLO-SBWL," en, *Agriculture*, vol. 15, n.º 7, pág. 685, mar. de 2025, ISSN: 2077-0472. DOI: 10.3390/agriculture15070685

[3] S. Yang, B. Wang, S. Ru, R. Yang y J. Wu, "Maize Seed Damage Identification Method Based on Improved YOLOV8n," en, *Agronomy*, vol. 15, n.º 3, pág. 710, mar. de 2025, ISSN: 2073-4395. DOI: 10.3390/agronomy15030710

[4] Y. Xia, A. Shen, T. Che, W. Liu, J. Kang y W. Tang, "Early Detection of Surface Mildew in Maize Kernels Using Machine Vision Coupled with Improved YOLOv5 Deep Learning Model," en, *Applied Sciences*, vol. 14, n.º 22, pág. 10 489, nov. de 2024, ISSN: 2076-3417. DOI: 10.3390/app142210489

[5] N. Pal Singh y R. P. Singh Rana, "A Systematic Review of Machine Learning Based Classification and Prediction Models for Grains (Maize)," en *2024 First International Conference on Data, Computation and Communication (ICDCC)*, Sehore, India: IEEE, nov. de 2024, págs. 469-475, ISBN: 979-8-3315-3295-6. DOI: 10.1109/ICDCC62744.2024.10961273

[6] S. Niu et al., "High accuracy identification of maize seed varieties based on a lightweight improved YOLOv8," en, *Scientific Reports*, vol. 15, n.º 1, pág. 18 541, mayo de 2025, ISSN: 2045-2322. DOI: 10.1038/s41598-025-00499-0

[7] L. Maolan, G. Zhenchang, L. Wenliang y C. Honghao, "Comparative review of Vision Transformer and YOLO in food and agriculture," en, *Journal of Food and Nutrition Research*, vol. 65, n.º 1, pág. 1, dic. de 2025, ISSN: 1336-8672, 1338-4260. DOI: 10.64122/HOYB1678

[8] M. Hussain, "YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection," en, *Machines*, vol. 11, n.º 7, pág. 677, jun. de 2023, ISSN: 2075-1702. DOI: 10.3390/machines11070677

[9] S. Niu et al., "Research on a Lightweight Method for Maize Seed Quality Detection Based on Improved YOLOv8," en, *IEEE Access*, vol. 12, págs. 32 927-32 937, 2024, ISSN: 2169-3536. DOI: 10.1109/ACCESS.2024.3365559

[10] D. Liu, J. Fang e Y. Zhao, "A Lightweight Dynamic Counting Algorithm for the Maize Seedling Population in Agricultural Fields for Embedded Applications," en, *Agronomy*, vol. 16, n.º 2, pág. 176, ene. de 2026, ISSN: 2073-4395. DOI: 10.3390/agronomy16020176

[11] R. Li et al., "Maize Kernel Batch Counting System Based on YOLOv8-ByteTrack," en, *Sensors*, vol. 25, n.º 17, pág. 5584, sep. de 2025, ISSN: 1424-8220. DOI: 10.3390/s25175584

[12] S. Mavaddati y M. Razavi, "An Optimized YOLO-ViT Hybrid Model for Enhanced Precision in Rice Classification and Quality Assessment," en, *International Journal of Engineering*, vol. 38, n.º 10, págs. 2435-2450, 2025, ISSN: 17281431, 17359244. DOI: 10.5829/ije.2025.38.10a.19

[13] C. Bi, N. Hu, Y. Zou, S. Zhang, S. Xu y H. Yu, "Development of Deep Learning Methodology for Maize Seed Variety Recognition Based on Improved Swin Transformer," en, *Agronomy*, vol. 12, n.º 8, pág. 1843, ago. de 2022, ISSN: 2073-4395. DOI: 10.3390/agronomy12081843

[14] S. Macwan, S. Warrier, V. K. Dabhi y H. B. Prajapati, "Maize Grain Classification Using Machine Learning," en, en *2025 International Conference on Innovations in Intelligent Systems: Advancements in Computing, Communication, and Cybersecurity (ISAC3)*, Bhubaneswar, India: IEEE, jul. de 2025, págs. 1-7, ISBN: 979-8-3315-3279-6. DOI: 10.1109/ISAC364032.2025.11156487

[15] Naciones Unidas, *La Agenda 2030 y los Objetivos de Desarrollo Sostenible: una oportunidad para América Latina y el Caribe.* Santiago: Comisión Económica para América Latina y el Caribe (CEPAL), dic. de 2018, Documento LC/G.2681-P/Rev.3, ISBN: 978-92-1-058643-6.

[16] Ministerio de Telecomunicaciones y de la Sociedad de la Información, "Estrategia para el Fomento del Desarrollo y Uso Ético y Responsable de la Inteligencia Artificial en el Ecuador (EFIA-EC)," Quito, Ecuador, Acuerdo Ministerial No. MINTEL-MINTEL-2025-0030, Reg. Of. Supl. No. 206, ene. de 2026.

[17] U. N. de Loja, "Líneas aprobadas de investigación UNL," *Serie de Publicaciones Institucionales*, vol. 1, n.º 1, págs. 1-100, mayo de 2021. dirección: https://unl.edu.ec/investigacion/lineas-investigacion

[18] Asamblea Nacional del Ecuador, "Ley Orgánica de Protección de Datos Personales," Quito, Ecuador, Reg. Of. Quinto Supl. No. 459, mayo de 2021.

[19] Y. Xia et al., "Detection of surface defects for maize seeds based on YOLOv5," en, *Journal of Stored Products Research*, vol. 105, pág. 102 242, feb. de 2024, ISSN: 0022474X. DOI: 10.1016/j.jspr.2023.102242

[20] S. Liu et al., "An improved YOLOv8 model for detecting damage types of maize kernels using proximal hyperspectral imaging," *Journal of Agriculture and Food Research*, vol. 27, pág. 102 813, mar. de 2026, ISSN: 26661543. DOI: 10.1016/j.jafr.2026.102813

[21] M. Liu, Y. Liu, Q. Wang, Q. He y D. Geng, "Real-Time Detection Technology of Corn Kernel Breakage and Mildew Based on Improved YOLOv5s," *Agriculture*, vol. 14, n.º 5, pág. 725, 7 de mayo de 2024, ISSN: 2077-0472. DOI: 10.3390/agriculture14050725

[22] N. Manakitsa, G. S. Maraslidis, L. Moysis y G. F. Fragulis, "A Review of Machine Learning and Deep Learning for Object Detection, Semantic Segmentation, and Human Action Recognition in Machine and Robotic Vision," *Technologies*, vol. 12, n.º 2, pág. 15, 23 de ene. de 2024, ISSN: 2227-7080. DOI: 10.3390/technologies12020015

[23] V. Kumar, P. S. S. Aydav y S. Minz, "Crop Seeds Classification Using Traditional Machine Learning and Deep Learning Techniques: A Comprehensive Survey," *SN Computer Science*, vol. 5, n.º 8, pág. 1031, 6 de nov. de 2024, ISSN: 2661-8907. DOI: 10.1007/s42979-024-03379-y

[24] M. A. R. Alif y M. Hussain, "YOLOV1 to YOLOV10: a comprehensive review of yolo variants and their application in the agricultural domain," 2024. DOI: https://doi.org/10.48550/arXiv.2406.10139

[25] R. Sapkota et al., "YOLO advances to its genesis: a decadal and comprehensive review of the You Only Look Once (YOLO) series," *Artificial Intelligence Review*, vol. 58, n.º 9, pág. 274, 11 de jun. de 2025, ISSN: 1573-7462. DOI: 10.1007/s10462-025-11253-3

[26] N. Jegham, C. Y. Koh, M. Abdelatti y A. Hendawi, *Yolo Evolution: A Comprehensive Benchmark and Architectural Review of Yolov12, Yolo11, and Their Previous Versions*, 2025. DOI: 10.2139/ssrn.5175639

[27] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, *You Only Look Once: Unified, Real-Time Object Detection*, 9 de mayo de 2016. DOI: 10.48550/arXiv.1506.02640 arXiv: 1506.02640[cs].

[28] S. Studer et al., "Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology," *Machine Learning and Knowledge Extraction*, vol. 3, n.º 2, págs. 392-413, 22 de abr. de 2021, ISSN: 2504-4990. DOI: 10.3390/make3020020

[29] W. Sun et al., "LWCD-YOLO: A Lightweight Corn Seed Kernel Fast Detection Algorithm Based on YOLOv11n," en, *Agriculture*, vol. 15, n.º 18, pág. 1968, sep. de 2025, ISSN: 2077-0472. DOI: 10.3390/agriculture15181968

[30] S. Chen, Y. Li, Y. Zhang, Y. Yang y X. Zhang, "Soft X-ray image recognition and classification of maize seed cracks based on image enhancement and optimized YOLOv8 model," *Computers and Electronics in Agriculture*, vol. 216, pág. 108 475, ene. de 2024, ISSN: 01681699. DOI: 10.1016/j.compag.2023.108475

9. Anexos

9.1. Declaración de uso de Inteligencia Artificial Generativa

En cumplimiento con las directrices de transparencia en la investigación e integridad académica, se declara el uso de herramientas de Inteligencia Artificial (IA) generativa como soporte técnico y lingüístico en la elaboración de este documento. Específicamente, se utilizaron las plataformas Gemini y NotebookLM para la revisión de estilo, la corrección ortográfica y gramatical, el refinamiento de la redacción y la optimización sintáctica de los párrafos. Asimismo, estas tecnologías sirvieron de apoyo para estructurar, depurar y formatear los elementos de código, tablas y entornos algorítmicos en el lenguaje de marcado LaTeX.

Es necesario precisar que la intervención de la IA generativa se limitó exclusivamente al procesamiento y ordenamiento de la información provista por el propio autor. La conceptualización del problema, el diseño del marco metodológico, la planificación del esquema experimental y la estructuración general de esta propuesta son el resultado del criterio directo y la autoría intelectual exclusiva del investigador, quien asume la responsabilidad total por el contenido técnico presentado.

9.2. Reporte Antiplagio

Informe de análisis
Compilatio Magister+ | UTPL-ECU

Romero_Geovanny_Trabajo_integración_curricular
ID : e000d6397181d31b6acb373967bcce077e91f1f8

15%
Textos sospechosos

Nombre del fichero : Romero_Geovanny_Trabajo_integración_curricular.txt
Tamaño del archivo original : 4,5 MB
Número de palabras : 13.649

Depositante : PAULA MERCEDES ALVAREZ CARRION
Fecha de depósito : 8 de julio de 2026
Tipo de carga : interface
fecha de fin de análisis : 8 de julio de 2026

Resumen (sección 1/3)

Localización de los textos sospechosos en el documento :



Incluido en el porcentaje de textos sospechosos :

Similitudes **2%**

Sintáctica 2% | Semántica

Pasajes con similitudes a fuentes encontradas en diferentes colecciones.



Detección de IA **14%**

Textos estilísticamente próximos a un texto generado por una IA.
Este índice es un indicador y no una prueba. Comprueba con el autor si domina los conocimientos mencionados en el documento.



No incluido en el porcentaje de textos sospechosos :

Textos entre comillas **3%**

Pasajes entre comillas, a menudo indicativos de una cita.

Fuentes de similitudes (sección 2/3)

Similitudes

2%

Pasajes con similitudes a fuentes encontradas en diferentes colecciones.



Fuente principal detectada

N°	Descripciones	Similitudes	Ubicaciones
1	YOLO Evolution: A Comprehensive Benchmark and Architectural... arxiv.org/html/2411.00201v3	<1%	
5	Aplicación de las normas técnicas presupuestarias para la... repositorio.utmachala.edu.ec/bitstream/48000/3368/6/ECUACE-2015-CA-C...	<1%	

Fuente con similitudes fortuitas

N°	Descripciones	Similitudes	Ubicaciones
2	oa.upm.es oa.upm.es/91287/1/TESIS_MASTER_ALEJANDRO_CASANOVA_MARTIN.pdf	<1%	
3	Muhammad Hussain FKHEA - Google Scholar scholar.google.com/citations?user=4iYh1isAAAAJ&hl=en	<1%	
4	YOLO Evolution: A Comprehensive Benchmark and Architectural... arxiv.org/pdf/2411.00201	<1%	
6	www.fundefaecuador.com www.fundefaecuador.com/wp-content/uploads/2024/11/FORMATO-CARA...	<1%	
7	Determinación del mejor algoritmo de reconocimiento de... dx.doi.org/10.57166/riqchary/v5.n1.2023.118	<1%	
8	YOLO para defectos de fabricación digital | Datision datision.com/blog/yolo-defectos-fabricacion-digital/	<1%	
9	Documento de otro usuario #428b7a Viene de de otro grupo	<1%	
10	Maize quality detection based on MConv-SwinT high-precision... journals.plos.org/plosone/article?id=10.1371/journal.pone.0312363	<1%	
11	www.proceedings.com www.proceedings.com/content/079/079771webtoc.pdf	<1%	
12	Constrained maximum correntropy criterion based sparse... link.springer.com/content/pdf/10.1007/s11760-025-04704-5.pdf	<1%	
13	Ultralytics YOLO Evolution: An Overview of YOLO26, YOLO11,... arxiv.org/html/2510.09653v2	<1%	

9.3. Reporte de asesorias

Universidad Nacional de Loja

COMISIÓN DE ARTICULACIÓN DE LAS FUNCIONES SUSTANTIVAS

REGISTRO DE LAS ACTIVIDADES DE TUTORÍA PARA LA ELABORACIÓN DEL TRABAJO DE INTEGRACIÓN CURRICULAR/TITULACIÓN

Facultad	FACULTAD DE LA ENERGÍA, LAS INDUSTRIAS Y LOS RECURSOS NATURALES NO RENOVABLES
Carrera/Programa:	COMPUTACIÓN - PRESENCIAL
Nombre y apellidos del docente asesor/director:	OSCAR MIGUEL CUMBICUS PINEDA
Tema del trabajo de integración curricular/titulación:	Prototipo de visión por computadora para clasificación superficial de granos de maíz
Nombres y apellidos del/los aspirante/s:	- GEOVANNY ISMAEL ROMERO SUQUILANDA
Periodo académico ordinario	MAR.26-AGO.26 GRADO

Nro	Fecha	Tiempo empleado en la tutoría	Tema tratado en la tutoría	Recomendaciones del Asesor/Director	Modalidad		Firma del estudiante/Registro Virtual	
					Presencial	Virtual		
1	8 de julio de 2026	60 minutos	Escaneo del proyecto por el sistema antiplagio	Revisar informe y de ser el caso modificar para la solicitud de pertinencia		x	GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
2	1 de julio de 2026	60 minutos	Revisión del documento final	Listo para pertinencia		x	GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
3	18 de junio de 2026	60 minutos	Revisión del cronograma y presupuesto	Presentar el documento completo para revisión final		x	GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
4	10 de junio de 2026	30 minutos	Revisión del marco teórico y metodología			x	GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
5	3 de junio de 2026	30 minutos	Revisión de la metodología			x	GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
6	27 de mayo de 2026	30 minutos	Revisión de los objetivos específicos y alcance	Realizar los cambios solicitados	x		GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
7	13 de mayo de 2026	30 minutos	Revisión del objetivo general	Redactar el objetivo general de acuerdo a la pregunta de investigación	x		GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
8	7 de mayo de 2026	30 minutos	Revisión de la pregunta de investigación	Aprobación de la pregunta de investigación	x		GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
9	23 de abril de 2026	60 minutos	Revisión de la teorización del problema	Realizar las correcciones y continuar con los otros párrafos	x		GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado
10	15 de abril de 2026	60 minutos	Revisión de la idea principal	Revisión de modelos Yolo para la detección, conteo y clasificación	x		GEOVANNY ISMAEL ROMERO SUQUILANDA	Validado

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
OSCAR MIGUEL CUMBICUS PINEDA

F) ----------
DOCENTE

F) ----------
DIRECTOR/A Y/O ENCARGADO/A DE LA GESTIÓN ACADÉMICA DE LA CARRERA